

Figura 1. The international 10/20 EEG system. Las letras F, T, C, P y O se refieren al lóbulo frontal, temporal, central, parietal y occipital respectivamente. Los electrodos con números pares se refieren a la posición en el hemisferio derecho, y los impares a la posición en el lóbulo izquierdo.

2. Objetivo

Como alternativa a la clasificación manual a cargo de los expertos de sueño, se busca clasificar automáticamente estadios de sueño a partir de la información de EEG registrada en una PSG convencional.

Para lograr esto se pretende desarrollar primero un aprendizaje de representación y posteriormente un aprendizaje residual de secuencia [5]. Con el primero se busca extraer características importantes de los datos crudos de EEG, mientras con el segundo se busca aprovechar las características aprendidas anteriormente para realizar una clasificación mas precisa de las etapas de sueño.

3. Dataset

Physionet Sleep-edf-expanded es una base de datos publica contiene registros de sueño de toda la noche, que contienen EEG, EOG, EMG de mentón y marcadores de eventos, algunos registros contienen respiración y temperatura corporal. Los hipnogramas correspondientes (patrones de sueño) fueron calificados manualmente en épocas de 30s por técnicos bien capacitados según el manual de Rechtschaffen y Kales [6] [7].

Dentro de la base, se encuentran 153 archivos **SC*** (SC = Sleep Cassette) que se obtuvieron en un estudio realizado entre 1987 y 1991 sobre los efectos de la edad sobre el sueño en caucásicos sanos de entre 25 y 101 años, sin ningún medicamento relacionado con el sueño. Se registraron dos PSG de aproximadamente 20 horas cada uno durante dos períodos posteriores de día y noche en los hogares de los sujetos [7]. El canal seleccionado para este proyecto es el EEG_pz (EEG lóbulo parietal referenciado a z) únicamente de 20 sujetos SC, la información en detalle se describen a continuación;

Tabla 1. Descripción del dataset de uso

Subjects Number	Stage (AASM)					Total Epochs EEG_pz	Size
	Wake	N1	N2	N3	REM		
20	2351	1783	10030	3068	3911	21143	410 MB

Los archivos originalmente vienen en formato .edf, estos son procesados y convertidos para su uso en dos extensiones diferentes .mat y .CSV

4. Métricas de desempeño

Machine learning

Las métricas de desempeño para este proyecto se enfocan en dos aspectos clave: rendimiento de clasificación y concordancia.

Para evaluar el rendimiento de clasificación, se utilizará la validación cruzada Leave One Subject Out Cross Validation (LOSSO). Se entrenará el modelo con 9 sujetos y se validará con 1 sujeto, con el objetivo de obtener un accuracy promedio mínimo del 75%. Para evaluar la concordancia entre las predicciones de la red neuronal y las clasificaciones de los expertos de sueño, se utilizará el índice Kappa de Cohen y gráficos de Bland Altman. El objetivo es obtener un índice al menos de 0.63.

Negocio

Este modelo será integrado a un dispositivo rastreador del sueño para consumidores que busca monitorear y cuantificar la calidad de sueño calculada a partir de las fases de sueño durante una noche de registro.

Criterio de éxito: el modelo desarrollado debe superar el 80% de ajuste para ser considerado satisfactorio y atractivo para el mercado. Se establecerá un proceso de evaluación continua para monitorear el rendimiento del modelo en datos nuevos y actualizados. Así mismo, se recopilarán comentarios y retroalimentación de los usuarios sobre la utilidad y satisfacción durante el uso del equipo. Esta información servirá para mejorar y refinar el modelo según sea necesario.

5. Referencias y resultados previos

Tabla 2. Resultados previos para clasificación de estadios de sueño con redes neuronales

Ref	Year	Technique	Features	Database	Stage	Accuracy %
[5]	2017	CNN to extract time invariant features, and bidirectional-Long Short-Term Memory to learn transition	Time invariants features	Sleep-EDF. Fpz-Cz and Pz-Oz EEG channels	Five: WAKE, N1, N2, N3, REM	82.0
[8]	2017	Single hidden layer neural network	Power Spectral density bands (Feature vector)	Own. FPz EEG channel	Three: NREM, REM, WAKE	0.63 Kappa
[9]	2016	Complex-valued neural network (CVANN) algorithm	Statistical features	Own. C3-A2 EEG channel	Six: WAKE, N1, N2, N3, N4, REM	93.84
[10]	2017	Convolutional neural network (CNN) based on five layers	Time-frequency image (TFI)	Own. Pz-Oz EEG channel	Four: WAKE, N2, N3, REM	88.83
[11]	2018	Mixed Neural Network, multi-layer perception (MLP) and a recurrent neural network (RNN)	Time-domain	Open access. Fp1-Fp2 EEG and EOG channels	Five: WAKE, N1, N2, N3, REM	83.35
[12]	2017	Three feed-forward network FFNN 12 neurons	Time-frequency (three methods)	Sleep-EDF. Pz-Oz EEG channel	Five: WAKE, N1, N2, N3, REM	81.1

Bibliografía

- [1] H. & C. A. I. Larramona Carrera, « Polisomnografía nocturna y métodos alternativos para el estudio de los trastornos respiratorios del sueño.,» *Sociedad española de neumología pediátrica (NEUMOPED)*, pp. (1:67-84), 2017).
- [2] Troester MM, Quan SF, Berry RB, et al, *The AASM Manual for the Scoring of Sleep and Associated Events, Rules, Terminology and Technical Specifications Version 3*, Darien , 2023.
- [3] A. & R. A. Kales, «A manual of standardized terminology, techniques and scoring system for sleep stages of human subjects,» *US Department of Health, Education and Welfare, Public Health Service, National Institutes of Health, National Institute of Neurological Diseases and Blindness, Neurological Information Network.*, 1968.
- [4] F. Tower y G. Road, *10/20 System Positioning Manual*, Hong Kong : Trans Cranial Technologies ldt, 2012.
- [5] A. Supratak, H. Dong, C. Wu y Y. Guo, «DeepSleepNet: a Model for Automatic Sleep Stage Scoring based on Raw Single-Channel EEG,» *IEEE TRANSACTIONS ON NEURAL SYSTEMS AND REHABILITATION ENGINEERING*, pp. 1998-2008, 2017.
- [6] B. Kemp, A. Zwinderman, B. Tuk, H. Kamphuisen y J. Oberyé., «Analysis of a sleep-dependent neuronal feedback loop: the slow-wave microcontinuity of the EEG,» *IEEE*, pp. 1185-1194, 2000.
- [7] A. Goldberger, L. Amaral, L. Glass, J. Hausdorff, P. C. Ivanov, R. Mark y H. E. Stanley, «PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals.,» p. e215–e220., 2000.
- [8] G. Garcia-Molina, K. Baehr, B. Steele, T. Tsoneva, S. Pfundtner, B. Riedner, D. P. White y G. Tononi, «Automatic characterization of sleep need dissipation using a single hidden layer neural network,» *European Signal Processing Conference (EUSIPCO)*, 2017.
- [9] M. Peker, «A New Approach for Automatic Sleep Scoring: Combining Taguchi Based Complex-Valued Neural Network and Complex Wavelet Transform,» *Department of Information Systems Engineering, Faculty of Technology*, 2016.
- [10] S. Xie, Y. Li, X. Xie, W. Wang y X. Duan, «The analysis and classify of sleep stage using deep learning network from single-channel EEG signal,» *Lecture Notes in Computer Science*, vol. 10637, 2017.

- [11] H. Dong, A. Supratak, W. Pan, C. Wu, P. M. Matthews y Y. Guo, «Mixed neural network approach for temporal sleep stage classification,» *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 26, p. 324–333, 2018.
- [12] M. Prucnal y A. G. Polak, «Effect of feature extraction on automatic sleep stage classification by artificial neural network,» *METROLOGY AND MEASUREMENT SYSTEMS*, vol. 24, p. 229–240, 2017.